

MÁSTER EN INTELIGENCIA ARTIFICIAL

DESARROLLO DE UN SISTEMA DE AUTENTICACIÓN BASADO EN LA BIOMETRÍA DEL COMPORTAMIENTO EN DISPOSITIVOS MÓVILES

Curso 2025/26 -

Trabajo dirigido por:
ROBERTO ALCARAZ MACHADO

DAVID JIMÉNEZ CASTRO
DNI: 76052663-N
e-mail: djimenezc1@student.universidadviu.com

Índice general

1. Introducción **1**

1.1. El Fundamento de la Biometría Conductual 1

1.2. Innovación Tecnológica y Arquitectura 2

2. Objetivos **5**

2.1. Objetivo General 5

2.2. Objetivos Específicos 5

2.3. Alcance y Limitaciones 7

3. Estado del Arte **9**

3.1. IJCB 2022 MobileB2C: Competición de Autenticación Basada en Comportamiento Móvil 9

3.2. BehaveFormer: A Framework with Spatio-Temporal Dual Attention Transformers for IMU enhanced Keystroke Dynamics . 11

3.3. Type2Branch: Keystroke Biometrics based on a Dual-branch Architecture with Attention Mechanisms and Set2set Loss . . 13

3.3.1. Evolución de las Arquitecturas de Aprendizaje Profundo 13

3.3.2. Funciones de Pérdida y Verificación 13

3.3.3. Métricas de Rendimiento en Autenticación Pasiva . . . 14

3.3.4. Importancia para la Autenticación Pasiva 14

3.4. Estado del Arte: Autenticación Continua y Ensamblados de Redes Profundas 14

3.4.1. Evolución de las Técnicas de Clasificación 15

3.4.2. Extracción de Características y Representación de Datos 15

3.4.3. Desafíos en la Autenticación Pasiva 16

3.5. NYIT Smartphone Activity Dataset: único referente del mismo corpus 18

4. Marco Teórico **19**

4.1. Sistemas de autenticación biométrica 19

4.2. Métodos de aprendizaje automático aplicados 21

4.2.1. Redes de Memoria a Largo Plazo 22

4.2.2. Ventajas frente a RNN's clásicas 23

4.2.3. Transformers y Mecanismos de Atención 24

4.3. Bases de datos y benchmarks del dominio 26

4.4. Privacidad y Consideraciones Éticas 26

4.4.1. Marco Normativo 26

4.4.2. Consideraciones Éticas del Sistema 28

5. Desarrollo del Proyecto **31**

5.1. Descripción del Problema 31

5.2. Metodología 32

5.2.1. Preprocesamiento y Extracción de Características . . . 32

5.2.2. Enfoque 1: Arquitectura basada en Transformer 33

5.2.3. Enfoque 2: Ensemble de Modelos Especializados por Modalidad 34

5.2.4. Protocolo de Evaluación 34

5.2.5. Dos pipelines (visión de conjunto) 36

5.3. Resultados obtenidos 36

5.3.1. Baseline de Referencia 36

5.3.2. Resultados del sistema propuesto (NYIT, eval leftover) 37

6. Resultados **39**

6.1. Protocolo y corpus 39

6.2. Unimodales 40

6.3. Ensemble y fusores 40

6.4. Transformer y ablación de scroll 40

6.5. Comparación Transformer frente a ensemble 41

6.6. Longitud de secuencia 41

6.7. Comparación con Random Forest (mismo protocolo) 41

6.8. IMU (experimento no propuesto) 42

6.9. Discusión frente a Cariello (mismo set) y al SOTA de otro corpus 43

6.10. Figuras 44

7. Conclusiones **49**

7.1. Objetivo general 49

7.2. Objetivos específicos 50

7.3. Conclusión 51

8. Limitaciones y trabajos futuros **53**

8.1. Limitaciones 53

8.2. Trabajos futuros 54

Bibliografía 55

Capítulo 1

Introducción

En el panorama actual de la ciberseguridad móvil, la dependencia de métodos de autenticación estática —como contraseñas, PINs o patrones de dibujo— presenta vulnerabilidades críticas frente a ataques de ingeniería social e interceptación. Si bien la biometría fisiológica (huella dactilar o reconocimiento facial) ha reforzado el perímetro de seguridad, estos métodos actúan como guardianes de "un solo paso" que no protegen la sesión una vez iniciada.

El presente proyecto propone el desarrollo de un **Sistema de Autenticación Basado en la Biometría del Comportamiento**, un enfoque que permite la verificación de identidad de forma **pasiva, continua y transparente** para el usuario.

1.1. El Fundamento de la Biometría Conductual

A diferencia de los rasgos físicos, la biometría conductual se centra en **cómo** interactúa el usuario con su dispositivo. Este sistema aprovecha la singularidad de los patrones neurofisiológicos y motores, analizando variables

clave capturadas de manera transparente:

- **Dinámica de Tecleo (*Keystroke Dynamics*):** Estudio de los tiempos de presión (*Dwell Time*), las latencias entre teclas (*Flight Time*) y los intervalos entre pulsaciones (*Inter-key Interval*).
- **Dinámica de Firma (*Signature Dynamics*):** Patrones de posición, presión, velocidad y aceleración durante el trazo de la firma en pantalla táctil.
- **Gestos de Desplazamiento (*Scroll Dynamics*):** Velocidad, aceleración, longitud y ángulo de los deslizamientos sobre la interfaz, como señal complementaria de la interacción táctil.

Los sensores inerciales (*IMU*) —acelerómetro, giroscopio y magnetómetro— aparecen de forma recurrente en el estado del arte (p. ej. BehaveFormer) como modalidad de fusión con el tecleo. En este trabajo se consideran como **precedente bibliográfico y línea de comparación opcional**, no como pilar del sistema propuesto.

1.2. Innovación Tecnológica y Arquitectura

Para superar las limitaciones de los modelos clásicos (como SVM o KNN), que presentan dificultades de escalabilidad en entornos masivos, este sistema se fundamenta en arquitecturas de **Aprendizaje Profundo (*Deep Learning*)**:

- **Dos enfoques comparables:** (i) un Transformer unificado con encoders por modalidad y *atención cruzada* entre tecleo, firma y scroll; (ii) un ensemble de expertos (LSTM de tecleo, CNN-LSTM de firma y MLP/CNN de scroll) con fusión a nivel de puntuación.
- **Modelos Híbridos y Atención:** Integración de CNN para características locales del trazo y LSTM para dependencias temporales, complementadas con mecanismos de atención sobre la secuencia de interacción.
- **Fusión Multimodal:** Combinación de dinámica de tecleo, firma y des-

plazamiento, con un experimento ablativo para cuantificar el beneficio marginal del scroll. Las arquitecturas tipo *STDAT* con IMU se tratan como trabajo relacionado, no como la arquitectura a implementar.

- **Funciones de Pérdida Avanzadas:** *Triplet Loss* en los expertos unimodales y *Set2set Loss* en el enfoque Transformer, para comparar flujos continuos contra el perfil de enrolamiento.

Capítulo 2

Objetivos

El presente trabajo tiene como propósito fundamental el diseño, desarrollo y evaluación de un sistema de autenticación continua y pasiva basado en la biometría del comportamiento en dispositivos móviles. A continuación se detallan los objetivos generales y específicos que guiarán la investigación.

2.1. Objetivo General

Desarrollar un sistema de autenticación basado en biometría conductual para dispositivos móviles que sea capaz de verificar la identidad del usuario de forma continua y transparente, sin requerir interacción explícita, mediante el uso de arquitecturas de aprendizaje profundo y fusión multimodal de dinámica de tecleo, dinámica de firma y gestos de desplazamiento.

2.2. Objetivos Específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

1. **Diseñar una arquitectura de aprendizaje profundo multimodal**

capaz de procesar de forma conjunta señales heterogéneas —dinámica de tecleo (*keystroke dynamics*), dinámica de firma en pantalla (*signature dynamics*) y gestos de desplazamiento (*scroll dynamics*)— para generar representaciones de identidad robustas frente a variaciones de contexto y dispositivo.

2. **Implementar y evaluar dos enfoques complementarios bajo un protocolo común**: un Transformer con atención cruzada entre modalidades, y un ensemble de modelos especializados (LSTM de tecleo, CNN-LSTM de firma y clasificador ligero de scroll) con fusión a nivel de puntuación.

3. **Explorar funciones de pérdida orientadas a la verificación**, en particular *Triplet Loss* (expertos unimodales) y *Set2set Loss* (enfoque Transformer), que permitan optimizar el sistema para la comparación de perfiles continuos de usuario en lugar de clasificaciones estáticas.

4. **Evaluar el rendimiento del sistema sobre benchmarks públicos reconocidos** en el dominio, tales como BehavePassDB, HuMIdb o Aalto DB, utilizando métricas estándar como el *Equal Error Rate* (EER) y el *Area Under the Curve* (AUC), con el objetivo de facilitar la comparación con trabajos previos. Los sistemas basados en tecleo e IMU (p. ej. BehaveFormer) se emplean como referencia bibliográfica, no como definición del sistema propuesto.

5. **Analizar el impacto de la longitud de secuencia** en la precisión de autenticación, buscando alcanzar una detección fiable con ráfagas cortas de actividad (en torno a 50 caracteres o eventos de tecleo), lo que se traduce directamente en una reducción del *Time-to-Detection* (TTD) ante posibles impostores. La inclusión del scroll se plantea como experimento ablativo de beneficio marginal.

6. **Garantizar el cumplimiento de los principios de privacidad y ética** aplicables al tratamiento de datos biométricos conductuales, siguiendo las directrices del RGPD y el principio de *Privacy by Design*,

con especial atención a la minimización de datos y la no recuperabilidad del contenido textual a partir de las métricas capturadas.

2.3. Alcance y Limitaciones

El sistema se circunscribe al ámbito de los dispositivos móviles con pantalla táctil. El escenario principal de uso es la escritura de texto libre (*free-text*), complementada con la firma manuscrita en pantalla y los gestos de desplazamiento. Quedan fuera del alcance de este trabajo la autenticación basada en biometría fisiológica (huella dactilar, reconocimiento facial) y el análisis de señales de voz o vídeo. Los sensores inerciales (IMU) no forman parte del sistema propuesto; pueden utilizarse únicamente como línea de comparación con el estado del arte.

Capítulo 3

Estado del Arte

El estado del arte en la biometría del comportamiento en dispositivos móviles abarca una amplia gama de técnicas y metodologías que buscan identificar y autenticar a los usuarios basándose en sus patrones de interacción con el dispositivo. A continuación, se presentan algunas de las investigaciones y desarrollos más relevantes en este campo.

3.1. IJCB 2022 MobileB2C: Competición de Autenticación Basada en Comportamiento Móvil

El trabajo de Stragapede et al. 2022*b* presenta una **evaluación comparativa** de sistemas de autenticación móvil basados en **biometría conductual**, capturada de manera transparente mientras el usuario interactúa con su dispositivo.

Base de Datos Utilizada

El estudio emplea la base pública **BehavePassDB**, recopilada en condiciones reales, que incluye:

- Dinámica de tecleo (*keystroke*)
- Lectura de texto (*text reading*)
- Deslizamiento de galería (*gallery swiping*)
- Toques en pantalla (*tapping*)
- Sensores como acelerómetro, giroscopio, magnetómetro, entre otros

Para el *benchmarking*, además de la identeficación del usuario legítimo, se consideran dos tipos de ataques de impostores:

- **Impostores aleatorios**: otro usuario con un dispositivo distinto.
- **Impostores hábiles**: individuos que intentan imitar al usuario legítimo.

Conclusiones

Los resultados de la competición **MobileB2C** muestran que la autenticación basada en comportamiento es **viable**, aunque sigue siendo un desafío complejo debido a la variabilidad del entorno y la dificultad de modelar múltiples modalidades de interacción.

Como contribución adicional, el estudio consolida **MobileB2C como una competición continua**, proporcionando una base de datos abierta y un protocolo estándar que facilita nuevas investigaciones en autenticación conductual bajo condiciones realistas.

Cuadro 3.1: Resultados durante la fase de evaluación (AUC [%])

#	Team	Mixed	Random	Skilled
Task 1: Keystroke				
1	NUS-UoA-UoM	**66.37**	**64.77**	**67.91**
2	HCI Essen	51.12	53.02	51.23
3	HBKU CS Lab	51.25	49.38	53.13
4	JAIRG	45.57	52.29	39.89
Task 2: Text Reading				
1	HCI Essen	**57.63**	**61.27**	**53.98**
2	NUS-UoA-UoM	54.89	58.49	51.29
3	JAIRG	50.63	50.00	41.25
4	HBKU CS Lab	48.27	59.42	37.13
Task 3: Gallery Swiping				
1	HBKU CS Lab	**61.54**	**67.35**	**55.73**
2	JAIRG	55.94	61.95	50.62
3	NUS-UoA-UoM	55.66	55.54	55.77
4	HCI Essen	54.72	57.30	51.17
Task 4: Tapping				
1	HBKU CS Lab	**59.58**	**57.22**	**61.94**
2	NUS-UoA-UoM	52.39	54.72	50.06
3	JAIRG	46.25	48.75	43.75
4	HCI Essen	43.89	40.16	47.62

3.2. BehaveFormer: A Framework with Spatio-Temporal Dual Attention Transformers for IMU enhanced Keystroke Dynamics

El trabajo de Senerath et al. 2023*a* propone *BehaveFormer*, un sistema de autenticación continua en dispositivos móviles basado en la biometría del

comportamiento. El enfoque combina dinámicas de tecleo con datos procedentes de sensores inerciales (IMU), presentes de forma estándar en la mayoría de teléfonos inteligentes. El núcleo del modelo es el *Spatio-Temporal Dual Attention Transformer* (STDAT), una arquitectura basada en *transformers* que emplea mecanismos de atención tanto temporal como de canal para capturar patrones característicos en el comportamiento del usuario.

Para la modalidad de tecleo, se utilizan secuencias de di-gramas y trigramas enriquecidas con tiempos de pulsación (*hold*), transiciones entre eventos y latencias entre teclas. En el caso de la IMU, se extraen derivadas de primer y segundo orden sobre los ejes tridimensionales y se aplica la transformada rápida de Fourier (FFT), obteniendo un vector descriptivo de 36 características por instante.

Cada modalidad es procesada por un STDAT independiente; posteriormente ambas representaciones se fusionan mediante concatenación para generar una incrustación final del usuario. El entrenamiento se realiza mediante *triplet loss*, favoreciendo que muestras del mismo usuario queden próximas en el espacio de representación y que las de distintos usuarios estén separadas.

El método se evalúa sobre tres conjuntos de datos ampliamente utilizados en autenticación continua: Aalto DB, HMOG DB y HuMIdb. Los resultados muestran mejoras significativas frente al estado del arte previo, alcanzando por ejemplo un EER del 1.80 % utilizando solo tecleo en Aalto DB, y un EER del 2.95 % al combinar tecleo e IMU en HuMIdb. Estas cifras confirman la eficacia de la fusión multimodal y del mecanismo de atención dual.

En conjunto, BehaveFormer demuestra que la combinación de información de tecleo y sensores inerciales, unida a arquitecturas basadas en transformers, constituye una vía sólida para sistemas de autenticación pasiva y continua, incrementando la seguridad sin exigir interacción explícita del usuario.

3.3. Type2Branch: Keystroke Biometrics based on a Dual-branch Architecture with Attention Mechanisms and Set2set Loss

En esta sección se analiza el artículo de González et al. 2025*a* que introduce *Type2Branch*, un sistema de autenticación basado en la dinámica de tecleo que se destaca por su capacidad de generalización en escenarios reales, superando las limitaciones de modelos anteriores como *TypeNet*.

3.3.1. Evolución de las Arquitecturas de Aprendizaje Profundo

Históricamente, los sistemas de *Keystroke Dynamics* se basaban en redes recurrentes simples para modelar secuencias temporales. Sin embargo, las limitaciones de estas para capturar patrones locales llevaron al desarrollo de enfoques híbridos:

- **Arquitectura Dual-Branch:** El modelo propone una rama de Redes Neuronales Convolucionales (CNN) para la extracción de características locales y una rama de Redes Recurrentes (RNN/LSTM) para las dependencias temporales globales.
- **Mecanismos de Atención:** A diferencia de los modelos precedentes como *TypeNet*, se introducen capas de atención que permiten al sistema ponderar eventos de pulsación específicos que poseen mayor carga discriminativa para la identidad del usuario.

3.3.2. Funciones de Pérdida y Verificación

Uno de los mayores avances del artículo es la transición de funciones de pérdida punto a punto hacia enfoques de conjuntos:

- **Set2set Loss:** Frente al tradicional *Triplet Loss*, la función *Set2set* permite comparar un conjunto de muestras de enrolamiento contra una muestra de consulta. Esto es crítico para la **autenticación pasiva**, donde la decisión se basa en el flujo continuo de datos y no en una única entrada estática.

3.3.3. Métricas de Rendimiento en Autenticación Pasiva

El rendimiento reportado establece un nuevo estándar para escenarios de texto libre (*free-text*) y dispositivos heterogéneos:

Cuadro 3.2: Rendimiento de Type2Branch en entornos reales.

Escenario	**Usuarios**	**EER (%)**	**Longitud de Secuencia**
Desktop (Escritorio)	15,000	0.77 %	50 caracteres
Mobile (Táctil)	5,000	1.03 %	50 caracteres

3.3.4. Importancia para la Autenticación Pasiva

El modelo demuestra que es posible alcanzar una alta tasa de precisión con ráfagas cortas de actividad (50 caracteres). En el contexto de la seguridad continua, esto reduce el *Time-to-Detection* (TTD) de un posible impostor, permitiendo una revocación de acceso casi instantánea sin intervención del usuario.

3.4. Estado del Arte: Autenticación Continua y Ensamblados de Redes Profundas

El estudio de la biometría de teclado (*Keystroke Dynamics*) ha transitado desde el análisis de textos fijos hacia la autenticación pasiva y continua en entornos de texto libre. El trabajo de Acien and et al. 2022 contextualiza este avance mediante la comparación de técnicas tradicionales frente a

arquitecturas de aprendizaje profundo.

3.4.1. Evolución de las Técnicas de Clasificación

La literatura previa se divide fundamentalmente en dos vertientes metodológicas:

- **Aproximaciones Clásicas:** Se basan en algoritmos de aprendizaje automático supervisado como *K-Nearest Neighbors* (KNN), *Naive Bayes* y *Support Vector Machines* (SVM). Aunque eficaces en datasets pequeños, presentan limitaciones de escalabilidad y precisión en escenarios de autenticación continua donde el flujo de datos es masivo y desestructurado.
- **Aprendizaje Profundo (Deep Learning):** El estado del arte reciente destaca el uso de Redes Neuronales Convolucionales (CNN) para extraer características espaciales de las pulsaciones y Redes Neuronales Recurrentes (RNN), específicamente LSTM, para capturar la dependencia temporal. Aversano et al. introducen el concepto de *Ensemble Learning*, combinando múltiples clasificadores base para reducir la varianza y mejorar la robustez del sistema.

3.4.2. Extracción de Características y Representación de Datos

El consenso en las investigaciones actuales identifica tres métricas temporales críticas para la biometría conductual:

1. **Dwell Time (DT):** El tiempo que una tecla permanece presionada.
2. **Flight Time (FT):** El intervalo entre la liberación de una tecla y la pulsación de la siguiente.
3. **Inter-key Interval (IKI):** El tiempo transcurrido entre dos pulsaciones consecutivas.

El artículo subraya que la integración de estos rasgos en arquitecturas profundas permite omitir la ingeniería de características manual, ya que la red aprende representaciones jerárquicas de los patrones de tecleo.

3.4.3. Desafíos en la Autenticación Pasiva

A pesar de los avances, el estado del arte identifica brechas significativas que este estudio busca solventar:

- **Fragmentación de Datos:** La mayoría de los estudios previos utilizan datasets pequeños (menos de 100 usuarios). El artículo destaca la necesidad de *benchmarks* masivos, proponiendo un dataset integrado de más de 160,000 usuarios.
- **Generalización:** La dificultad de los modelos para mantener la precisión cuando el usuario cambia de contexto de escritura o de dispositivo.
- **Toma de Decisión Continua:** La transición de una autenticación de un solo paso (login) a una monitorización constante sin fricción para el usuario.

Estado del Arte: Biometría Conductual en Dispositivos Móviles

El artículo de Stragapede et al. 2022*a* sitúa su investigación en el contexto de la autenticación pasiva mediante biometría conductual en smartphones, analizando tanto la interacción táctil como los sensores de movimiento (background sensors).

Clasificación de Técnicas Anteriores

Los autores clasifican los trabajos previos principalmente en base a las modalidades biométricas y las arquitecturas de procesamiento:

- **Dinámica de Tecleo (Keystroke Dynamics):** Se divide en escenarios de *texto fijo* (contraseñas) y *texto libre*. Se mencionan aproximaciones basadas en redes neuronales recurrentes, específicamente Long Short-Term Memory (LSTM) para autenticación a gran escala.
- **Gestos Táctiles (Touch Gestures):** Técnicas que analizan el desplazamiento (scrolling), toques (tapping) y dibujo de patrones.
- **Sensores de Movimiento (Background Sensors):** Uso de acelerómetros, giroscopios y magnetómetros para capturar patrones físicos del usuario durante la interacción.
- **Arquitecturas de Aprendizaje:** El artículo distingue entre modelos estadísticos tradicionales y enfoques modernos de Deep Learning (como CNNs para gestos y LSTMs para secuencias temporales).

Limitaciones Identificadas

El estudio subraya varias deficiencias en la literatura actual:

1. **Fragmentación de Modalidades:** La mayoría de los estudios se centran en una sola modalidad (solo tecleo o solo acelerómetro), perdiendo la sinergia de la fusión multimodal.
2. **Escalabilidad y Realismo:** Muchos trabajos utilizan bases de datos pequeñas o recolectadas en entornos de laboratorio controlados que no reflejan el uso cotidiano ("in-the-wild").
3. **Ventanas de Tiempo Elevadas:** Algunos sistemas requieren periodos de observación demasiado largos para alcanzar precisiones aceptables, lo que reduce la eficacia de la autenticación pasiva inmediata.

Problema Específico a Resolver

El vacío que este artículo intenta llenar es la **evaluación exhaustiva de la fusión de múltiples biometrías conductuales** (tecleo, scroll, dibujo, sensores de fondo) bajo un protocolo común y utilizando una base de datos

pública de gran escala (*HuMIdb*). El objetivo es determinar cuál es la combinación mínima de sensores y tiempo de análisis necesaria para lograr una autenticación robusta y transparente.

3.5. NYIT Smartphone Activity Dataset: único referente del mismo corpus

El dump empleado en este TFM es el *Smartphone Activity Dataset* de NYIT Cariello et al. 2025*b*. En la literatura pública, el único grupo que reporta autenticación sobre ese conjunto (o sobre la recolección de laboratorio de la que deriva) es el laboratorio LAMP, con Cariello y colaboradores. No hay, a fecha de esta memoria, un Transformer o un TypeNet/BehaveFormer reentrenado en NYIT con el que medir el sistema propuesto en igualdad de corpus.

Cariello et al. Cariello et al. 2025*a* combinan *swipe*, IMU del teléfono y captura de movimiento corporal en estudio Vicon. Los verificadores son clásicos: *Random Forest*, k-NN, SVM de una clase y distancia de Manhattan escalada. Con mocap alcanzan EER 5,4–6,4 % en ventanas de 1–5 s; solo *swipe* e IMU del teléfono quedan en 15,7 % con latencia de 60 s.

El trabajo posterior Cariello et al. 2026 alinea rasgos de cuerpo e IMU a cada pulsación. De nuevo el mejor clasificador es *Random Forest* (no hay LSTM ni atención cruzada). Con mocap reportan EER $\approx$ 1,5 % en ventanas de 1 s; el baseline de teléfono (tecleo/IMU, sin cuerpo) se sitúa en 9,5–11,9 %. Esas cifras no son un SOTA Transformer en NYIT: dependen de marcadores ópticos de laboratorio y de un protocolo (sesiones lab, ventanas de un segundo) distinto del leftover *open-set* de este trabajo.

Capítulo 4

Marco Teórico

4.1. Sistemas de autenticación biométrica

La biometría se ha consolidado como el pilar fundamental de la identidad digital moderna, desplazando a los sistemas basados en posesión y conocimiento. Este marco teórico analiza la biometría no solo como una herramienta técnica, sino como un proceso científico de reconocimiento de individuos basado en sus características biológicas y conductuales.

La biometría se basa en la premisa de que ciertos rasgos físicos o de comportamiento son únicos, estables y medibles. Para que una característica humana sea considerada un indicador biométrico eficaz, debe cumplir con siete criterios fundamentales definidos por Jain et al. 2008 (Sección 1.6 *biometric characteristics*):

1. **Universalidad**: Cada persona debe poseer el rasgo.
2. **Unicidad**: Dos personas no deben tener el mismo rasgo (distinguibilidad).
3. **Permanencia**: El rasgo debe ser *invariante* en el tiempo.
4. **Colectabilidad**: El rasgo debe poder medirse cuantitativamente.

5. **Rendimiento**: Precisión y velocidad en el reconocimiento.
6. **Aceptabilidad**: Grado en que la población está dispuesta a utilizar el sistema.
7. **Resistencia al fraude**: Dificultad para engañar al sistema mediante artefactos.

Los sistemas biométricos se basan en un flujo de trabajo estándar dividido en dos fases críticas:

1. **Alistamiento o Registro**: En esta fase un sistema de sensores captura la huella biométrica del individuo. Posteriormente se elimina el ruido y se extraen las características de interés de la huella. Finalmente se genera una representación matemática de la huella. Es importante remarcar que no se guarda la imagen original de la huella sino su representación matemática.
2. **Reconocimiento**: En esta fase se distinguen dos procesos:
   - **Verificación**: Se realiza la comparación *uno a uno* de la huella (*¿Es, realmente, la persona que dice ser?*).
   - **Identificación**: Se realiza la comparación *uno a varios* de la huella (*¿Quién es esta persona?*).

(Incluir un diagrama de los dos sistemas quedaría bien, en el siguiente hito estará)

Modalidades de biometría conductual

En la literatura científica es común ver que la biometría se clasifica en tres grupos:

1. **Biometría Fisiológica**: Se centra en la medida directa de diferentes partes del cuerpo como: la huella dactilar, el reconocimiento facial, ocular, geometría de la mano y su patrón de venas.

2. **Biometría Conductual**: Analiza patrones de comportamientos que pueden ser aprendidos o adquiridos como: la mecanografía, la marcha (forma de caminar) y la firma.

3. **Biometría Química**: Se basa en las características químicas del individuo como el ADN o el olor corporal (compuestos órganicos volátiles emitidos por la piel).

En este trabajo nos centraremos en la biometría conductual o del comportamiento.

Métricas de Rendimiento y Errores

Para medir la eficacia del sistema biométrico usaremos principalmente las siguientes tasas de error fundamentales:

1. **FAR (*False Acceptance Rate*)**: Probabilidad de que el sistema acepte por error a un impostor.

2. **FRR (*False Rejection Rate*)**: Probabilidad de que el sistema rechace erróneamente a un usuario legítimo.

3. **ERR (*Equal Error Rate*)**: El punto donde FAR y FRR son iguales.

4.2. Métodos de aprendizaje automático aplicados

La evolución de la biometría moderna está intrínsecamente ligada al avance del *Aprendizaje Automático* y del *Aprendijaze Profundo*. Estas arquitecturas permiten pasar de una comparación basada en reglas manuales a una extracción de características latentes con dimensionalidad alta.

4.2.1. Redes de Memoria a Largo Plazo

Las redes neuronales LSTM *(Long Short-Term Memory)* son una variante de las Redes Neuronales Recurrentes *(RNN)* diseñadas para evitar el problema del desvanecimiento del gradiente *(vanishing gradient)*, permitiendo aprender dependencias a largo plazo en datos secuenciales Hochreiter and Schmidhuber 1997.

Arquitectura y Mecanismo de Compuertas

A diferencia de una RNN estándar, cuya celda oculta se actualiza completamente en cada paso temporal, la LSTM introduce un estado de celda C_t que actúa como una "memoria" capaz de retener información relevante durante largas secuencias. Este mecanismo se regula mediante tres compuertas diferenciables:

- **Compuerta de olvido** f_t: Decide qué información del estado anterior debe descartarse. Se define como:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{4.1}$$

- **Compuerta de entrada** i_t: Controla qué nueva información se almacena en el estado de celda:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \tag{4.2}$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \tag{4.3}$$

- **Compuerta de salida** o_t: Determina qué parte del estado de celda se expone como salida:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \tag{4.4}$$

$$h_t = o_t \cdot \tanh(C_t) \tag{4.5}$$

Donde σ es la función sigmoide, W son las matrices de pesos entrenables, b los sesgos, h_{t-1} el estado oculto anterior y x_t la entrada en el instante t. La actualización del estado de celda combina el olvido selectivo del pasado con la incorporación de nueva información:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \tag{4.6}$$

donde $\odot$ denota el producto elemento a elemento *(Hadamard)*.

4.2.2. Ventajas frente a RNN's clásicas

El problema del desvanecimiento del gradiente en RNN estándar surge cuando, durante la retropropagación a través del tiempo *(BPTT)*, el gradiente se multiplica repetidamente por valores menores que uno, haciendo que la señal de error se extinga antes de alcanzar pasos temporales lejanos. Las LSTM mitigan este efecto gracias al estado de celda, que permite que el gradiente fluya sin atenuación a través de largos intervalos temporales siempre que la compuerta de olvido permanezca abierta Goodfellow et al. 2016.

Aplicación a la Biometría Conductual

En el contexto de la autenticación basada en biometría del comportamiento, las LSTM resultan especialmente adecuadas por la naturaleza inherentemente secuencial de las señales capturadas. Para la **dinámica de tecleo**, cada pulsación genera un vector de características temporales —Dwell Time (DT), Flight Time (FT) e Inter-key Interval (IKI)— que forman una secuencia variable en longitud. La LSTM es capaz de modelar las dependencias entre pulsaciones no adyacentes, capturando el ritmo global de escritura del usuario, algo imposible de representar con modelos estáticos como SVM o KNN Acien et al. 2022*a*.

Del mismo modo, para señales de **sensores inerciales** (acelerómetro y giroscopio), la LSTM aprende patrones de micro-gestualidad que se manifies-

tan en ventanas temporales de cientos de milisegundos, extrayendo representaciones del comportamiento físico del usuario al sostener e interactuar con el dispositivo.

Trabajos como TypeNet Acien et al. 2022*a* y BehaveFormer Senerath et al. 2023*b* han demostrado que las LSTM alcanzan resultados competitivos en autenticación continua de texto libre, siendo posteriormente complementadas con mecanismos de atención y arquitecturas basadas en Transformers para capturar dependencias tanto locales como globales en la secuencia de interacción.

4.2.3. Transformers y Mecanismos de Atención

Originalmente propuestos por Vaswani et al. para el procesamiento del lenguaje natural, los Transformers han revolucionado múltiples campos de la inteligencia artificial gracias a su capacidad para modelar relaciones globales entre todos los elementos de una secuencia de forma paralela, superando las limitaciones de las arquitecturas recurrentes en cuanto a eficiencia computacional y captura de dependencias a larga distancia Vaswani et al. 2017.

El Mecanismo de Atención

El núcleo del Transformer es el mecanismo de *Scaled Dot-Product Attention*, que opera sobre tres matrices: consultas *(Queries, Q)*, claves *(Keys, K)* y valores *(Values, V)*, todos ellos proyecciones lineales de la entrada. La atención se calcula como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{4.7}$$

donde d_k es la dimensión de las claves, y el factor $\frac{1}{\sqrt{d_k}}$ evita que el producto escalar crezca excesivamente para dimensiones altas, estabilizando el gradiente durante el entrenamiento Vaswani et al. 2017.

En la práctica se emplea *Multi-Head Attention*, que aplica h cabezas de atención en paralelo sobre distintas proyecciones del espacio de representación, permitiendo al modelo atender simultáneamente a diferentes aspectos de la secuencia:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)W^O \tag{4.8}$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \tag{4.9}$$

Atención Dual Espacio-Temporal en Biometría Conductual

En el contexto de la autenticación basada en biometría del comportamiento, el mecanismo de atención adquiere una relevancia especial, ya que no todas las pulsaciones o instantes temporales contribuyen por igual a la identidad del usuario. Arquitecturas como BehaveFormer Senerath et al. 2023*b* introducen el *Spatio-Temporal Dual Attention Transformer (STDAT)*, que aplica dos dimensiones de atención de forma simultánea:

- **Atención Temporal**: Pondera la relevancia de cada instante en la secuencia de pulsaciones, identificando qué momentos del flujo de tecleo son más discriminativos para verificar la identidad.
- **Atención de Canal**: Opera sobre las características extraídas de los sensores inerciales (IMU), determinando qué ejes del acelerómetro o giroscopio aportan mayor información identitaria en cada contexto de uso.

Fusión Multimodal mediante Atención

Una de las ventajas más relevantes de los Transformers es su capacidad natural para la **fusión multimodal**. En el precedente BehaveFormer Senerath et al. 2023*b*, cada modalidad —dinámica de tecleo y señales IMU— se trata como una secuencia de tokens y el mecanismo de atención aprende a qué fuente dar mayor peso en cada instante, sin reglas de fusión manuales. El presente trabajo reutiliza ese principio de atención cruzada, aplicándolo a las modalidades del sistema propuesto —tecleo, firma en pantalla y scroll—, y lo

contrasta con la fusión clásica a nivel de puntuación (ensemble de expertos). Esto mantiene la IMU en el marco teórico como modalidad del estado del arte, no como rama del modelo a desarrollar.

Type2Branch González et al. 2025*b* extiende este principio incorporando capas de atención sobre una arquitectura dual CNN-LSTM, permitiendo al modelo ponderar eventos de pulsación específicos con mayor carga discriminativa, lo que se traduce en mejoras significativas del Equal Error Rate (EER) frente a modelos precedentes como TypeNet.

4.3. Bases de datos y benchmarks del dominio

Aquí incluiré lo que utilice para comparar más adelante...

4.4. Privacidad y Consideraciones Éticas

El desarrollo de sistemas de autenticación basados en biometría conductual implica la captura, procesamiento y almacenamiento de datos de carácter personal de especial sensibilidad. En consecuencia, cualquier implementación debe enmarcarse en el conjunto normativo vigente en materia de protección de datos, tanto a nivel europeo como nacional.

4.4.1. Marco Normativo

Reglamento General de Protección de Datos (RGPD)

El Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, conocido como RGPD Parlamento Europeo and Consejo de la Unión Europea 2016, establece el marco general de protección de datos personales en la Unión Europea. En su artículo 9, el RGPD clasifica los **datos biométricos** como una categoría especial de datos personales, cuyo tratamiento queda prohibido con carácter general salvo que concurra alguna de las excepciones tasadas,

entre las que destacan:

- El **consentimiento explícito** del interesado para uno o varios fines específicos.
- La necesidad del tratamiento por razones de **interés público esencial**.
- Fines de **investigación científica**, siempre que se apliquen las garantías adecuadas.

Adicionalmente, el RGPD consagra una serie de principios de obligado cumplimiento para cualquier sistema que trate datos biométricos conductuales:

- **Minimización de datos**: únicamente deben recogerse los datos estrictamente necesarios para el fin declarado. En el contexto de este sistema, esto implica limitar la captura a las métricas temporales de tecleo (DT, FT, IKI), las series de trazo de la firma y los descriptores de gestos de desplazamiento, evitando el almacenamiento del contenido textual introducido por el usuario.
- **Limitación de la finalidad**: los datos recogidos no podrán utilizarse para fines distintos a la autenticación del usuario para el que fueron enrolados.
- **Exactitud y actualización**: los perfiles biométricos conductuales deben mantenerse actualizados, dado que los patrones de comportamiento del usuario pueden evolucionar con el tiempo debido a factores como el estado emocional, la fatiga o el cambio de dispositivo.
- **Limitación del plazo de conservación**: los datos biométricos no deben conservarse más tiempo del necesario para cumplir la finalidad del tratamiento.
- **Integridad y confidencialidad**: el sistema debe garantizar la seguridad de los datos mediante cifrado y controles de acceso adecuados.

Ley Orgánica de Protección de Datos y Garantía de los Derechos Digitales (LOPDGDD)

En el ámbito nacional español, la Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y Garantía de los Derechos Digitales Jefatura del Estado 2018 complementa y adapta el RGPD al ordenamiento jurídico español. En materia de datos biométricos, la LOPDGDD refuerza las obligaciones del responsable del tratamiento y establece garantías adicionales, entre las que destacan:

- La obligatoriedad de realizar una **Evaluación de Impacto relativa a la Protección de Datos (EIPD)** antes de implementar cualquier sistema que trate datos biométricos a gran escala, tal y como exige el artículo 35 del RGPD.
- El reconocimiento explícito del **derecho a la portabilidad** de los perfiles biométricos, permitiendo al usuario solicitar la transferencia o eliminación de su perfil conductual en cualquier momento.
- La figura del **Delegado de Protección de Datos (DPD)**, cuya designación puede ser obligatoria cuando el tratamiento de datos biométricos se realice a gran escala.

4.4.2. Consideraciones Éticas del Sistema

Más allá del cumplimiento normativo estricto, el diseño de un sistema de autenticación conductual plantea una serie de consideraciones éticas que deben abordarse desde las fases tempranas del desarrollo.

Transparencia y Consentimiento Informado

Dado que la biometría conductual opera de forma pasiva y transparente para el usuario, existe el riesgo de que este no sea plenamente consciente de los datos que se están recopilando. Por ello, es imprescindible garantizar que el usuario reciba una información clara, comprensible y accesible sobre

el funcionamiento del sistema antes de otorgar su consentimiento, evitando el uso de cláusulas genéricas o formulaciones técnicas ininteligibles.

Privacidad desde el Diseño

El principio de *Privacy by Design* Cavoukian 2009, incorporado al artículo 25 del RGPD como *protección de datos desde el diseño y por defecto*, exige que las medidas de privacidad se integren en la arquitectura del sistema desde su concepción, y no como un añadido posterior. En la práctica, esto se traduce en decisiones de diseño como:

- Almacenar únicamente representaciones vectoriales cifradas del perfil conductual, nunca las secuencias de pulsaciones en bruto.
- Aplicar técnicas de **anonimización** o **seudonimización** que impidan vincular el perfil biométrico con la identidad real del usuario en caso de brecha de seguridad.
- Garantizar que el modelo entrenado no permita reconstruir el contenido textual original a partir de las métricas temporales capturadas.

Sesgos y Equidad del Sistema

Los modelos de aprendizaje profundo pueden presentar sesgos en su rendimiento en función de características del usuario como la edad, condición motora o nivel de familiaridad con el dispositivo. Un sistema de autenticación conductual que presente tasas de error significativamente distintas entre grupos de usuarios podría generar situaciones de discriminación inadvertida. Por ello, es necesario evaluar el rendimiento del sistema de forma estratificada y adoptar medidas correctoras cuando se detecten disparidades.

Revocabilidad del Perfil Biométrico

A diferencia de la biometría fisiológica, los patrones conductuales son, en cierta medida, revocables: si el perfil de un usuario se ve comprometido, es posible reentrenar el modelo con nuevas muestras. No obstante, esto implica

mantener protocolos claros de gestión del ciclo de vida del perfil biométrico, incluyendo procedimientos de re-enrolamiento y eliminación segura de perfiles obsoletos.

Capítulo 5

Desarrollo del Proyecto

5.1. Descripción del Problema

El problema central de este trabajo es la autenticación continua y pasiva de usuarios en dispositivos móviles a partir de su biometría conductual. A diferencia de los mecanismos de autenticación estática —contraseñas, PINs o biometría fisiológica— que únicamente verifican la identidad en el momento del acceso, el objetivo es mantener una verificación activa durante toda la sesión sin que el usuario deba realizar ninguna acción adicional. Este enfoque plantea un problema de **verificación biométrica de una clase** (*one-class* o *open-set*): dado un perfil conductual enrolado para un usuario legítimo, el sistema debe decidir, a partir de una ventana corta de interacción, si el individuo que está operando el dispositivo corresponde a dicho perfil o se trata de un impostor. La dificultad inherente reside en que durante la fase de entrenamiento no se dispone de muestras etiquetadas de todos los posibles impostores, lo que impide formular el problema como una clasificación cerrada convencional. Las modalidades conductuales seleccionadas para este trabajo son tres, elegidas por su complementariedad y por la riqueza de información identitaria que aportan:

- **Dinámica de tecleo (*keystroke dynamics*)**: secuencias de tiempos

de pulsación (*Dwell Time*, DT), tiempos de vuelo entre teclas (*Flight Time*, FT) e intervalos entre pulsaciones consecutivas (*Inter-key Interval*, IKI). Constituye la modalidad más estudiada en la literatura y ofrece alta discriminabilidad incluso con ráfagas cortas de texto.

- **Dinámica de firma (*signature dynamics*)**: patrones de presión, velocidad y aceleración durante el trazo de la firma en pantalla táctil. Aporta una señal de alta varianza inter-usuario y baja varianza intra-usuario cuando el individuo firma de forma natural.
- **Gestos de desplazamiento (*scroll dynamics*)**: características extraídas de los movimientos de deslizamiento sobre la pantalla, incluyendo velocidad, aceleración, longitud del trazo y ángulo de desplazamiento. Su inclusión está condicionada al análisis del beneficio marginal que aporta en la fusión multimodal.

El principal desafío técnico es la **heterogeneidad temporal** de las señales: la dinámica de tecleo es discreta y de longitud variable, la firma es una señal continua de corta duración, y el scroll produce eventos esporádicos dependientes del contexto de uso. El sistema debe ser capaz de integrar estas tres fuentes de forma coherente y tomar decisiones de autenticación con latencia mínima, idealmente tras menos de 50 eventos de interacción.

5.2. Metodología

Para abordar el problema descrito, se propone una metodología experimental comparativa basada en dos enfoques arquitectónicos complementarios, cuyo rendimiento se evaluará bajo un protocolo común.

5.2.1. Preprocesamiento y Extracción de Características

Previo al modelado, cada modalidad requiere un pipeline de preprocesamiento específico:

- **Tecleo**: a partir de los eventos de pulsación se extraen las tripletas (DT_i, FT_i, IKI_i) para cada tecla i de la secuencia. Las secuencias se segmentan en ventanas deslizantes de longitud fija N (objetivo: $N = 50$ eventos), con solapamiento configurable para la autenticación continua. Los valores atípicos se filtran mediante umbrales basados en percentiles y las secuencias se normalizan con estadísticos calculados por usuario en la fase de enrolamiento.
- **Firma**: se extraen series temporales de posición (x_t, y_t), presión p_t y sus derivadas de primer y segundo orden. La señal se remuestrea a una frecuencia fija para garantizar la homogeneidad de la representación de entrada.
- **Scroll**: se caracterizan cada gesto de deslizamiento mediante un vector de rasgos agregados: velocidad media, velocidad máxima, aceleración media, longitud euclidiana del trazo, duración y desviación angular respecto al eje vertical.

5.2.2. Enfoque 1: Arquitectura basada en Transformer

El primer enfoque propone una arquitectura *end-to-end* inspirada en BehaveFormer Senerath et al. 2023*b* y Type2Branch González et al. 2025*b*, que procesa las tres modalidades de forma conjunta mediante mecanismos de atención. Cada secuencia de interacción se trata como una serie de *tokens* de entrada. Un codificador Transformer independiente por modalidad —con capas de *Multi-Head Self-Attention* y redes *feed-forward* posicionales— genera una representación de contexto para cada fuente de señal. Las representaciones resultantes se fusionan mediante un módulo de **atención cruzada entre modalidades** (*cross-modal attention*), que aprende a ponderar dinámicamente la contribución de cada fuente en función del contexto de uso. La función de pérdida empleada para el entrenamiento es *Set2set Loss* González et al. 2025*b*, que compara un conjunto de muestras de enrolamiento $\mathcal{S} = \{s_1, \ldots, s_k\}$ contra una muestra de consulta q, permitiendo una estimación más robusta de la similitud que el clásico *Triplet Loss* puntual:

$$\mathcal{L}_{\text{set2set}} = \max\left(0,\ m + d\big(\bar{e}_{\mathcal{S}},\, q^{+}\big) - d\big(\bar{e}_{\mathcal{S}},\, q^{-}\big)\right) \tag{5.1}$$

donde $\bar{e}_{\mathcal{S}}$ es la representación agregada del conjunto de enrolamiento, q^{+} una muestra del usuario legítimo, q^{-} una muestra de impostor y m el margen de separación.

5.2.3. Enfoque 2: Ensemble de Modelos Especializados por Modalidad

El segundo enfoque adopta una estrategia modular: se entrena un modelo especializado e independiente para cada modalidad conductual, y sus puntuaciones de similitud se combinan mediante una estrategia de fusión a nivel de *score*.

- **Modelo de tecleo**: red LSTM bidireccional seguida de una capa de proyección métrica, entrenada con *Triplet Loss*, siguiendo la línea de TypeNet Acien et al. 2022*b*.
- **Modelo de firma**: red CNN-LSTM que extrae características locales de los segmentos del trazo (CNN) y modela la dinámica temporal global (LSTM).
- **Modelo de scroll**: clasificador ligero basado en un perceptrón multicapa (MLP) o una red CNN-1D sobre los vectores de rasgos agregados por gesto.

La fusión de puntuaciones se explorará mediante tres estrategias: combinación lineal con pesos fijos, combinación lineal con pesos aprendidos, y un meta-clasificador entrenado sobre las puntuaciones de los modelos base.

5.2.4. Protocolo de Evaluación

Ambos enfoques se evalúan bajo un protocolo común de verificación *open-set*, inspirado en las directrices de MobileB2C Stragapede et al. 2022*c* y

adaptado al dump NYIT realmente usado:

- **Partición de usuarios**: 49 / 16 / 18 usuarios en tren / desarrollo / evaluación (*seed* 42), sin solapamiento de identidades entre particiones.
- **Enrolamiento leftover**: $k = 5$ primeras ventanas por modalidad para el perfil; el resto de ventanas del mismo usuario constituyen las consultas genuinas (sin muestrear).
- **Impostor**: aleatorio (usuarios distintos del split de evaluación). NYIT no define un protocolo de impostor hábil.
- **Longitud oficial**: ventanas de tecleo $N = 50$ (stride 25). Ablación $N \in \{25, 50, 100\}$ solo en el experto BiLSTM de tecleo.
- **Métricas**: EER (primaria), AUC, FAR a FRR 1 % y TTD con $k = 2$ ventanas consecutivas por debajo del umbral fijado en desarrollo.

La firma en NYIT no es una firma legal: se emplea un *proxy* de trazo táctil (*swipe*). Tecleo y *swipe* proceden de **ensayos distintos**, de modo que la fusión es a nivel de usuario, no de ensayo simultáneo. El tecleo del dump es solo *press* (DT nulo; FT = IKI).

Un experimento adicional de IMU (36-D alineada a ventanas de tecleo) se documenta como réplica de la línea BehaveFormer; **no forma parte del sistema propuesto** ni de su tabla de resultados.

5.2.5. Dos pipelines (visión de conjunto)

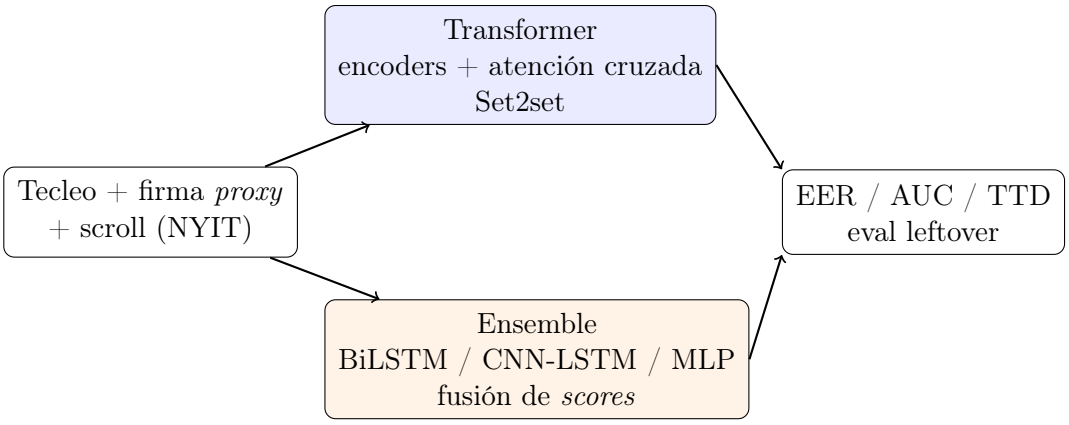


Figura 5.1: Pipelines comparados en este trabajo. La IMU queda fuera del diagrama (réplica, no propuesta).

5.3. Resultados obtenidos

Las cifras de esta sección sustituyen las estimaciones iniciales (EER del orden del 1–3 %). Dichas estimaciones **no se materializan** en NYIT: el dump es *press-only*, la firma es un *proxy* de *swipe* y la fusión no es simultánea a nivel de ensayo. El detalle, las curvas DET y la discusión frente a Cariello (mismo set) y al SOTA de otro corpus se recogen en el Capítulo 6.

5.3.1. Baseline de Referencia

A continuación se recogen EER publicados: primero SOTA de **otro** corpus (no son el umbral que este sistema deba superar en NYIT) y, debajo, Cariello et al. como único referente del mismo set.

Cuadro 5.1: Referencias de EER (%). TypeNet / Type2Branch / BehaveFormer / MobileB2C son SOTA **ajena** (otro corpus). Cariello es el único referente publicado sobre NYIT; usa RF/k-NN/SVM y mocap, no un Transformer.

Sistema	**Modalidad**	**Dataset**	**EER (%)**
TypeNet Acien et al. 2022*b*	Tecleo	Aalto	2,20
Type2Branch González et al. 2025*b*	Tecleo	Mobile	1,03
BehaveFormer Senerath et al. 2023*b*	Tecleo + IMU	HuMIdb	2,95
MobileB2C top-1 Stragapede et al. 2022*c*	Keystroke	BehavePassDB	AUC: 66,37
Cariello RF+mocap Cariello et al. 2026	Tecleo+IMU+Vicon	NYIT lab	≈1,5
Cariello teléfono Cariello et al. 2026	Tecleo/IMU (sin cuerpo)	NYIT lab	9,5–11,9
Cariello swipe+IMU Cariello et al. 2025*a*	Swipe+IMU teléfono	NYIT lab	15,7

Cuadro 5.2: Rendimiento obtenido del sistema propuesto (EER %, eval leftover, $N = 50$). IMU excluida. El Transformer 3-mod usa 545 pares genuinos (tope de scroll); el resto de filas de ensemble y ablación de tecleo usan 2278.

Enfoque	**Modalidades**	**EER (%)**	**Observaciones**
Transformer unificado	Tecleo + firma + scroll	24,60	Mejor del propuesto; AUC 0,83
Transformer unificado	Tecleo + firma	28,14	El scroll sí aporta en el TF
Ensemble (meta)	Tecleo + firma + scroll	28,98	Mejor fusor de scores
Ensemble (fijo)	Tecleo + firma	36,62	Peor que solo tecleo (z reclamado)
Transformer unimodal	Tecleo	44,59	DT nulo; lejos de TypeNet/Aalto

5.3.2. Resultados del sistema propuesto (NYIT, eval leftover)

La fusión por atención cruzada sí mejora al ensemble de scores en este dump. El scroll es útil en el Transformer y perjudicial o irrelevante en el ensemble. La firma *proxy* no discrimina (EER unimodal próximo al 50 %). Un experimento IMU aparte alcanza EER 34,63 % en tecleo+IMU (1/EER); esa cifra no entra en la Tabla 5.2.

Capítulo 6

Resultados

6.1. Protocolo y corpus

Los resultados de este capítulo proceden de una única campaña de evaluación sobre el dump NYIT *home+lab cleaned* (iPhone XR), sin reentrenamiento posterior a las corridas archivadas en `data/eval_run/`. El protocolo es *open-set* y *user-disjoint*: 49 usuarios de entrenamiento, 16 de desarrollo y 18 de evaluación (*seed* 42). El enrolamiento usa las $k = 5$ primeras ventanas de cada modalidad; las consultas son el leftover completo. El impostor es aleatorio (otros usuarios del mismo split); NYIT no define impostor hábil. La longitud oficial de tecleo es $N = 50$. El umbral operativo se fija en desarrollo (EER) y se aplica en evaluación. No se persistió texto crudo.

Dos advertencias de lectura son imprescindibles. Primera: el Transformer de tres modalidades se evalúa sobre 545 pares genuinos (el tope lo impone el scroll), mientras que el ensemble de tres modalidades y las ablaciones de tecleo usan 2278; las curvas y barras no deben compararse como si compartieran el mismo N. Segunda: TypeNet, Type2Branch y BehaveFormer (Tabla 5.1) son SOTA de **otro** corpus (Aalto/HuMIdb) y no se dibujan en los mismos ejes que las figuras de este capítulo. El único referente publicado sobre NYIT es Cariello et al. Cariello et al. 2025*a*, 2026: verificadores RF/k-NN/SVM y,

cuando el EER baja del 2 %, captura Vicon. No existe un Transformer SOTA en este dump con el que igualar arquitectura y protocolo.

6.2. Unimodales

En evaluación leftover, las modalidades aisladas se sitúan cerca del azar práctico salvo un ligero margen del tecleo en el Transformer (EER 44,59 %, AUC 0,59). La firma *proxy* y el scroll unimodales rinden EER 47–50 % (AUC $\approx$ 0,50). El dump de tecleo es solo *press*: el tiempo de pulsación (DT) es nulo y el tiempo de vuelo coincide con el IKI, lo que empobrece la señal respecto a TypeNet. La firma no es un trazo legal de rúbrica, sino un *swipe* reutilizado como *proxy*.

6.3. Ensemble y fusores

Entre las estrategias de fusión a nivel de *score*, el meta-clasificador es el único que mejora de forma clara al experto de tecleo con z reclamado (EER 28,98 % frente a 30,37 %). Los fusores lineal fijo, 1/EER y softmax aprendido quedan por encima del 33 % de EER; el aprendido (35,69 %) no supera al fijo. Añadir firma *proxy* y scroll al ensemble con pesos fijos **empeora** el EER respecto a solo tecleo (36,62 % frente a 30,37 %). La fusión de scores no logra extraer identidad de canales próximos al azar.

6.4. Transformer y ablación de scroll

El Transformer de tres modalidades es el mejor sistema propuesto: EER 24,60 %, AUC 0,830 (545 genuinos, 9265 impostores). Al enmascarar el scroll en el mismo *checkpoint* el EER sube a 28,14 % (2278 genuinos): el scroll **sí** aporta en este enfoque. Enmascarar también la firma deja el EER prácticamente igual (28,14 %), coherente con la nula discriminabilidad unimodal del *proxy*. El unimodal de tecleo del Transformer (44,59 %) es peor que el experto

BiLSTM con z reclamado en el pipeline fused (30,37 %), lo que indica que la ganancia del TF está en la atención cruzada, no en el encoder de tecleo aislado.

6.5. Comparación Transformer frente a ensemble

Bajo el mismo split de usuarios, el Transformer 3-mod (EER 24,60 %, tasa TTD 97,7 %) supera al ensemble meta (EER 28,98 %, tasa TTD 41,2 %). La Figura 6.1 muestra el compromiso FAR/FRR; la curva IMU (tecleo+IMU) se incluye como réplica, no como candidato propuesto. La comparación de EER en la Figura 6.2 resume la misma ordenación, con la salvedad del N de pares.

6.6. Longitud de secuencia

La ablación del BiLSTM de tecleo con $N \in \{25, 50, 100\}$ produce EER 48,88 %, 47,56 % y 46,48 % (Figura 6.3). Alargar la ventana ayuda poco y no reproduce el salto que TypeNet reporta en Aalto a $N = 50$. El TTD se mide en número de ventanas, de modo que N mayor retrasa la decisión en eventos de tecla aunque el EER baje décimas.

6.7. Comparación con Random Forest (mismo protocolo)

Este experimento no replica Cariello et al.: no hay mocap Vicon, no hay split por sesión del mismo usuario ni ventanas de 1 s. Se fija el leftover NYIT de este TFM ($k = 5$, $N = 50$, impostor aleatorio) y solo cambia el verificador. Un *Random Forest* de rasgos agregados (IKI con DT nulo, vector de scroll 6-D, descriptores de la serie de firma *proxy*) se ajusta en *dev* y se evalúa en

leftover. Un segundo RF (L3) sustituye al meta-clasificador sobre el triplete de *scores* de los expertos congelados. No se ejecutó RF sobre embeddings (L2). Cifras: `data/rf_run/index.json`.

En eval leftover el mejor RF es el meta de scores (EER 30,32 %, AUC 0,762). No bate al ensemble meta (28,98 %) ni al Transformer 3-mod (24,60 %). El RF de tecleo (32,01 %) sí mejora el unimodal BiLSTM (47,56 %). Concatenar firma *proxy* y scroll al RF de rasgos baja poco el EER (32,01 % → 30,95 %): el canal extra no discrimina, igual que en el ensemble. La Figura 6.6 y la Tabla 6.1 resumen la ordenación. El 1,5 % de Cariello **no** se pinta en el eje. IMU y mocap no entran aquí.

Las probabilidades del bosque L1 no se calibran entre *dev* y *eval*: el τ de EER de *dev* produce un rechazo casi total en eval. El ranking de sistemas se lee por **EER eval**, no por ese punto operativo. En L3 el τ_{dev} sí da un compromiso (FAR 0,34 / FRR 0,21), aún peor en EER que el meta neuronal.

Cuadro 6.1: Random Forest en el leftover propio (eval). No es réplica de Cariello.

Sistema	**EER (%)**	**AUC**	**Genuinos**
RF tecleo (L1)	32,01	0,767	2278
RF 3-mod rasgos (L1)	30,95	0,756	2278
RF meta de scores (L3)	30,32	0,762	2278
Ensemble meta 3-mod	28,98	0,796	2278
Transformer 3-mod	24,60	0,830	545

6.8. IMU (experimento no propuesto)

La Tabla 6.2 y la Figura 6.4 recogen la réplica tecleo+IMU. El unimodal IMU es azar (51,06 %); la fusión 1/EER baja el EER de tecleo de 47,56 % a 34,63 %. Esa mejora no entra en la tabla del sistema propuesto. BehaveFormer (2,95 % en HuMIdb) no es comparable 1:1.

Cuadro 6.2: Réplica IMU en NYIT (eval leftover). No es el sistema propuesto.

Sistema	**EER (%)**
IMU unimodal	51,06
Tecleo unimodal (mismo protocolo)	47,56
Tecleo + IMU (1/EER)	34,63

6.9. Discusión frente a Cariello (mismo set) y al SOTA de otro corpus

Sobre **este** dump, Cariello et al. son el único referente Cariello et al. 2025*a*, 2026, 2025*b*. Sus arquitecturas no son Transformers: plantillas de rasgos y RF, k-NN, SVM de una clase o Manhattan escalada. El EER $\approx$ 1,5 % (tecleo, 1 s) y el 5,4–6,4 % (*swipe*, 1–5 s) incluyen mocap de laboratorio (Vicon). El baseline de **solo teléfono** que ellos mismos publican queda en 9,5–11,9 % (tecleo/IMU, 1 s) y 15,7 % (*swipe*+IMU, 60 s). Ni siquiera ese baseline es 1:1 con este TFM: ellos usan lab, dos sesiones del mismo usuario y ventanas de un segundo ancladas al evento; aquí el protocolo es *open-set* leftover ($N = 50$, press-only, fusión no simultánea, sin Vicon). Un RF de rasgos y un RF-meta de scores en **ese** leftover (Tabla 6.1) quedan en EER 30–32 %: la cabeza clásica no recupera el 1,5 % ni supera al Transformer. No hay un Transformer SOTA en NYIT contra el que medir el 24,60 % más allá de esta comparación interna.

TypeNet, Type2Branch y BehaveFormer ($\approx$ 1–3 % en Aalto/HuMIdb) siguen siendo SOTA **ajena**: otro dispositivo, otra señal (DT real, IMU de HuMIdb) y otro protocolo. El ranking interno (Transformer > ensemble meta > RF-meta > unimodales) es interpretable en NYIT; el salto a operación tipo Aalto o tipo Vicon no lo es. MobileB2C (AUC mixed 66,37 % en BehavePassDB) es, de nuevo, otro corpus.

6.10. Figuras

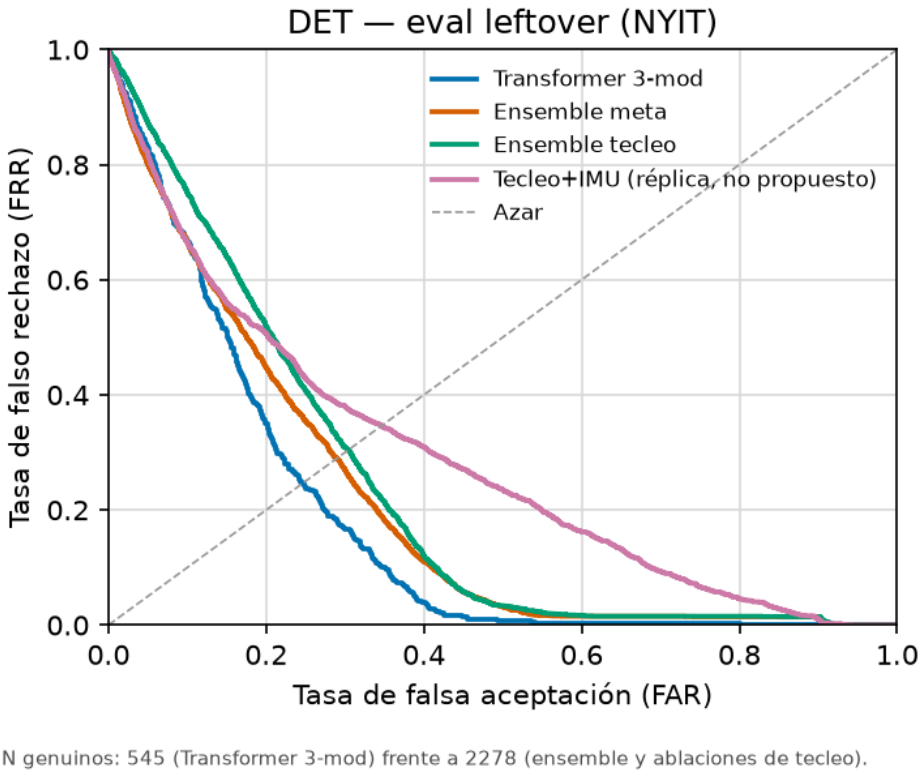


Figura 6.1: Curvas DET en evaluación leftover (NYIT). El Transformer 3-mod opera mejor en el compromiso FAR/FRR que el ensemble meta. La serie tecleo+IMU es réplica, no propuesta. Nota: 545 frente a 2278 pares genuinos según sistema.

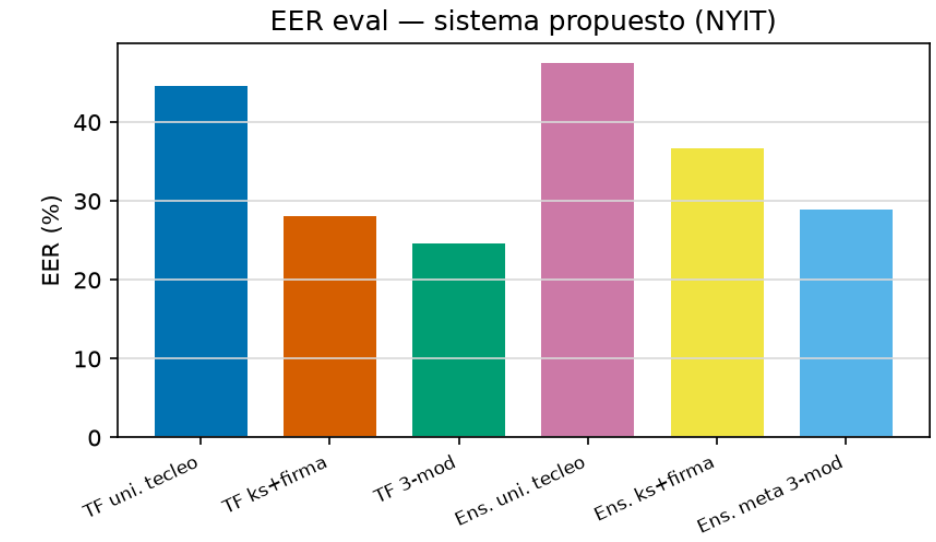


Figura 6.2: EER (%, eval) del sistema propuesto. El scroll reduce el EER del Transformer y no ayuda al ensemble. IMU ausente a propósito.

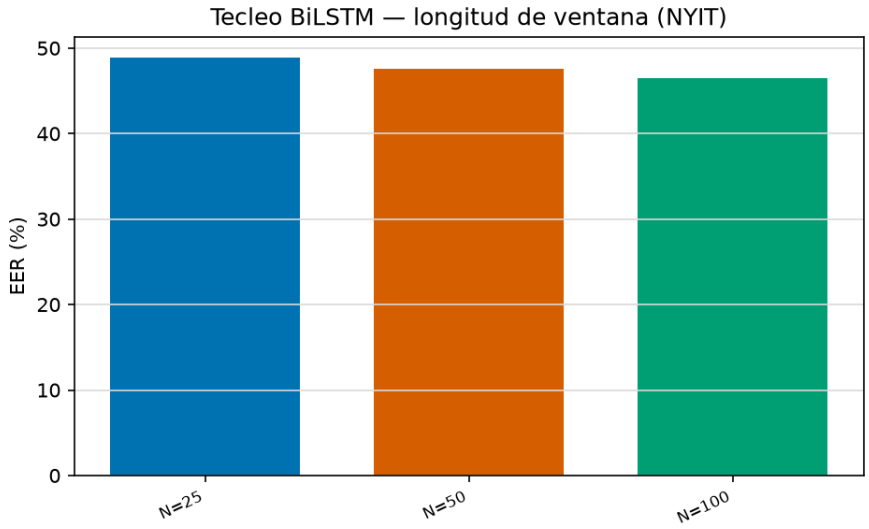


Figura 6.3: EER del BiLSTM de tecleo frente a la longitud de ventana. No hay salto comparable al de TypeNet en Aalto.

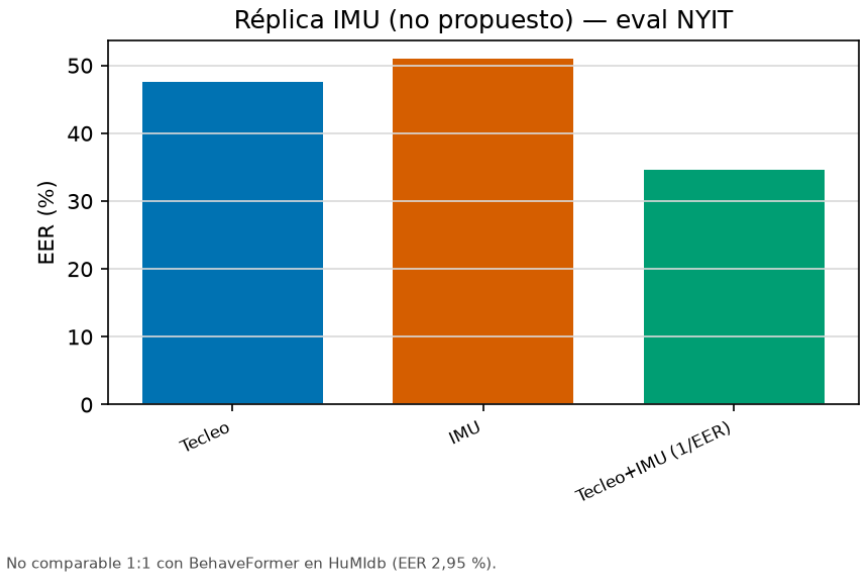


Figura 6.4: EER de la réplica IMU (no propuesto). HuMIdb/BehaveFormer no se pintan en el mismo eje.

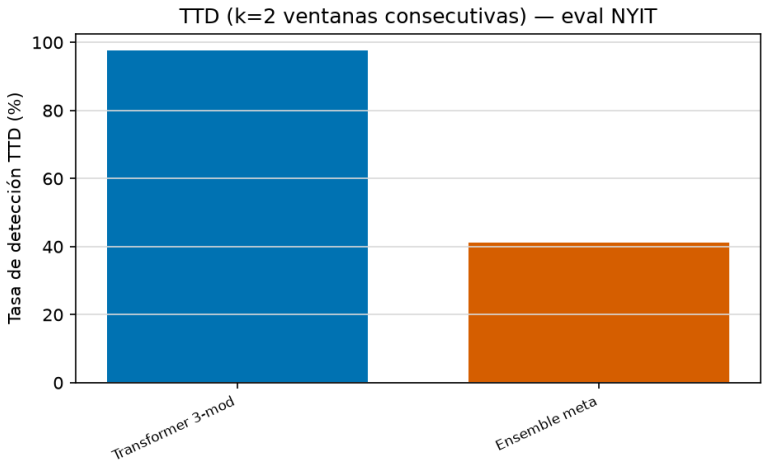


Figura 6.5: Tasa de detección TTD ($k = 2$ ventanas consecutivas). El Transformer marca impostor en más secuencias que el ensemble meta.

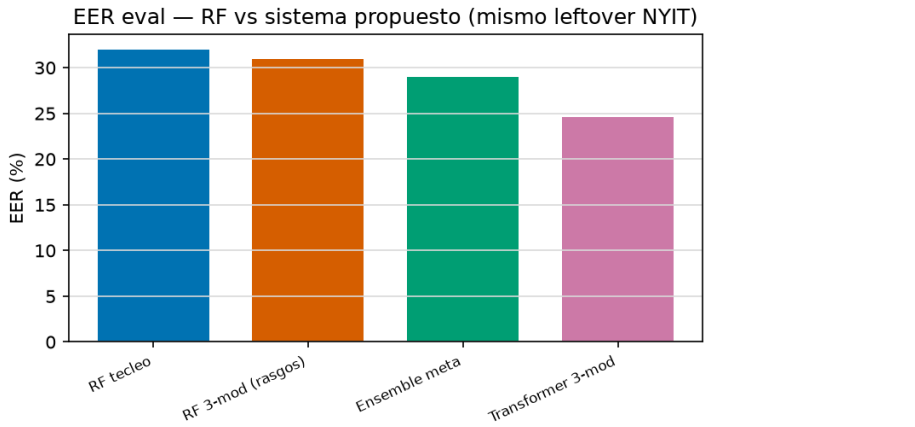


Figura 6.6: EER (%, eval leftover NYIT) del Random Forest de rasgos frente al ensemble meta y al Transformer 3-mod, mismo protocolo. Cariello 1,5 % no figura en el eje (otro split, mocap). Nota: 545 frente a 2278 pares genuinos según sistema.

Cuadro 6.3: Resumen eval leftover del sistema propuesto (EER y AUC). Cifras de `tables.json`.

Sistema	**EER (%)**	**AUC**	**Genuinos**
Transformer 3-mod	24,60	0,830	545
Transformer tecleo+firma	28,14	0,796	2278
Ensemble meta 3-mod	28,98	0,796	2278
Ensemble solo tecleo (z reclamado)	30,37	0,773	2278
Ensemble tecleo+firma (fijo)	36,62	0,702	2278
Transformer unimodal tecleo	44,59	0,586	2278

Capítulo 7

Conclusiones

Este capítulo cierra el trabajo frente a los objetivos del Capítulo 2 y a las cifras de evaluación leftover sobre NYIT. El detalle experimental, las figuras y las tablas están en el Capítulo 6; las limitaciones y las líneas abiertas, en el Capítulo 8.

7.1. Objetivo general

Se ha diseñado, implementado y evaluado un verificador *open-set* de autenticación continua y pasiva en un smartphone público (dump NYIT *home+lab cleaned*, iPhone XR), con fusión de dinámica de tecleo, firma *proxy* (*swipe*) y gestos de desplazamiento. El sistema opera sobre ventanas de interacción sin exigir un gesto de login y sin persistir el texto tecleado.

Ese objetivo se cumple como **demostrador de arquitectura y protocolo**, no como sustituto de un factor biométrico de alta seguridad. El mejor sistema propuesto —Transformer de tres modalidades— alcanza AUC 0,83 en leftover de evaluación, de modo que el ranking genuino/impostor es viable. El EER 24,60 % no admite un umbral de baja fricción: en el punto de error igual se acepta y se rechaza del orden de uno de cada cuatro intentos. Las estimaciones iniciales de EER 1–3 % (Capítulo 5) **no se materializan** en

este corpus (tecleo solo *press*, firma que no es rúbrica, fusión no simultánea a nivel de ensayo).

7.2. Objetivos específicos

1. **Arquitectura multimodal.** Un Transformer con encoders por modalidad y atención cruzada, entrenado con *Set2set Loss*, produce la mejor representación conjunta del dump. La firma *proxy* no aporta identidad en unimodal (EER $\approx 50\,\%$); el scroll sí reduce el EER del Transformer (28,14 % $\rightarrow$ 24,60 %) y no ayuda al ensemble.

2. **Dos enfoques bajo el mismo protocolo.** Transformer y ensemble (BiLSTM / CNN-LSTM / MLP con fusión de *scores*) se evalúan con los mismos splits *user-disjoint* (49/16/18, *seed* 42), $k = 5$, leftover e impostor aleatorio. La atención cruzada supera a la mejor fusión de puntuaciones (meta: EER 28,98 %). Un *Random Forest* de rasgos y un RF-meta sobre los mismos *scores* de expertos, en ese leftover, tampoco baten al Transformer (mejor RF: 30,32 %). La diferencia con Cariello et al. no se explica por "usar RF en vez de una red".

3. **Pérdidas de verificación.** *Triplet Loss* en los expertos y *Set2set* en el Transformer permiten comparar un perfil de enrolamiento contra consultas continuas. El umbral se fija en desarrollo (EER) y se aplica en evaluación.

4. **Evaluación y referentes.** El corpus ejecutado es NYIT, no Aalto, HuMIdb ni BehavePassDB. TypeNet, Type2Branch y BehaveFormer se citan como SOTA **ajena**. El único referente del mismo set es Cariello et al. (RF/k-NN/SVM + mocap Vicon, otro protocolo). No hay un Transformer SOTA publicado en NYIT con el que igualar cifras.

5. **Longitud de secuencia y TTD.** En el BiLSTM de tecleo, $N \in \{25, 50, 100\}$ apenas mueve el EER (48,88 %, 47,56 %, 46,48 %): no hay salto tipo TypeNet. El TTD ($k = 2$ ventanas) muestra que el Trans-

former marca impostor en más secuencias que el ensemble; no modela tiempo de reloj de una sesión real.

6. **Privacidad.** No se persistió texto de las pulsaciones. Las trazas versionables son métricas, incrustaciones y puntuaciones con identificadores seudónimos, alineado con minimización (RGPD) y *Privacy by Design*.

La IMU se documentó como experimento adicional (fusión tecleo+IMU: EER 34,63 %). No forma parte del sistema propuesto ni de su tabla de resultados.

7.3. Conclusión

En NYIT leftover, el orden estable es Transformer 3-mod > ensemble meta > RF-meta > RF de rasgos > unimodales próximos al azar. Open-set continuo es viable en **ranking** y no lo es como login operativo tipo Aalto o tipo Vicon. El trabajo aporta un pipeline reproducible, una comparación honesta de arquitecturas (incluida una cabeza clásica en el mismo protocolo) y una lectura explícita de los límites del dump. Lo que queda abierto —DT real, firma legal alineada, impostor hábil, más dispositivos, Aalto/HuMIdb con el mismo código— se detalla en el capítulo siguiente.

Capítulo 8

Limitaciones y trabajos futuros

8.1. Limitaciones

El dump NYIT empleado no incluye tiempos de liberación de tecla: el *dwell time* está ausente y el *flight time* coincide con el IKI. La firma no es una rúbrica legal, sino un *proxy* de *swipe*. Tecleo y gesto táctil ocurren en ensayos distintos, de modo que no hay fusión temporalmente alineada. No hay protocolo de impostor hábil. Un solo modelo de dispositivo (iPhone XR) impide hablar de heterogeneidad de hardware. TypeNet, Type2Branch y BehaveFormer se citan como SOTA ajena (Aalto/HuMIdb), no reentrenada aquí. El único referente del mismo set es Cariello et al. (RF/k-NN/SVM + mocap); no hay un Transformer SOTA publicado en NYIT.

La cabeza clásica (Random Forest de rasgos y RF-meta de scores) se evaluó en el mismo leftover y no bate al Transformer; clonar el protocolo de Cariello con Vicon, lab y ventanas de un segundo sigue fuera de alcance. El τ de EER de *dev* del RF de rasgos no se calibra a eval: el ranking se lee por EER, no por ese umbral.

El N de pares genuinos difiere entre el Transformer 3-mod (545, tope de scroll) y el ensemble (2278). Comparar EER sin esa nota sobreestima o

subestima diferencias. El TTD usa una regla de $k = 2$ ventanas consecutivas y no modela el tiempo de reloj de una sesión real. El experimento IMU, aunque archivado, no replica HuMIdb ni el STDAT de BehaveFormer.

8.2. Trabajos futuros

Las extensiones naturales son: (i) un corpus con DT/FT reales y, si se mantiene la modalidad de firma, trazos de rúbrica en el mismo ensayo que el tecleo; (ii) impostor hábil y más de un dispositivo; (iii) entrenar y evaluar en Aalto o HuMIdb con el mismo código, sin mezclar ejes con NYIT; (iv) calibrar umbrales por usuario y estudiar TTD en tiempo de pared; (v) sustituir el *proxy* de firma o eliminarlo del sistema propuesto si sigue en azar; (vi) explotar **rasgos que el dump ya contiene** y este pipeline no usa en el sistema propuesto. El *dwell* no se puede inventar: no hay *release*. Sí se pueden enriquecer los IKI (autocorrelación, histogramas, pausas, FFT), la cinemática del *swipe* (curvatura, jerk) y, sobre todo, la IMU de teléfono ya extraída como *sidecar* (tecleo+IMU en leftover: EER 34,63 %, peor que el Transformer 3-mod). En lab hay además series Vicon y, en algunos trials, *face tracking*; alinear IMU (o mocap) a cada pulsación como Cariello, sin salir del teléfono, sería la comparación de rasgos pendiente. Sit/walk y casa/lab son etiquetas de contexto, no identidad nueva.

Recolectar firma legal y bajar el EER mediante reentrenamiento del Transformer quedan fuera del alcance ya cerrado de esta memoria.

Bibliografía

Acien, A. y et al.: 2022, *Expert Systems with Applications*

Acien, A., Morales, A., Vera-Rodriguez, R., Tolosana, R., y Fierrez, J.: 2022a, *IEEE Transactions on Biometrics, Behavior, and Identity Science* **4(1)**, 57

Acien, A., Morales, A., Vera-Rodriguez, R., Tolosana, R., y Fierrez, J.: 2022b, *IEEE Transactions on Biometrics, Behavior, and Identity Science* **4(1)**, 57

Cariello, N., Eslinger, R., Gallagher, R., Kurtzer, I., Gasti, P., y Balagani, K. S.: 2025a, *IEEE Transactions on Biometrics, Behavior, and Identity Science* **7(1)**, 3

Cariello, N., Gallagher, R., Balagani, K., Kurtzer, I., y Gasti, P.: 2025b, *New York Institute of Technology Smartphone Activity Dataset*

Cariello, N., Nguyen, L., Gallagher, R., Kurtzer, I., Balagani, K. S., y Gasti, P.: 2026, *IEEE Transactions on Biometrics, Behavior, and Identity Science*, Accepted

Cavoukian, A.: 2009

González, N., Stragapede, G., Vera-Rodriguez, R., y Tolosana, R.: 2025a, *Type2Branch: Keystroke Biometrics based on a Dual-branch Architecture with Attention Mechanisms and Set2set Loss*

González, N., Stragapede, G., Vera-Rodriguez, R., y Tolosana, R.: 2025b, *arXiv preprint*

Goodfellow, I., Bengio, Y., y Courville, A.: 2016, *Deep Learning*, MIT Press, Cambridge, MA

Hochreiter, S. y Schmidhuber, J.: 1997, *Neural Computation* **9(8)**, 1735

Jain, A. K., Flynn, P. J., y Ross, A. A. (eds.): 2008, *Handbook of Biometrics*, Springer Science+Business Media, LLC, New York, NY, USA

Jefatura del Estado: 2018, *Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y Garantía de los Derechos Digitales*

Parlamento Europeo y Consejo de la Unión Europea: 2016, *Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos*

Senerath, D., Tharinda, S., Vishwajith, M., Rasnayaka, S., Wickramanayake, S., y Meedeniya, D.: 2023a, *BehaveFormer: A Framework with Spatio-Temporal Dual Attention Transformers for IMU enhanced Keystroke Dynamics*

Senerath, D., Tharinda, S., Vishwajith, M., Rasnayaka, S., Wickramanayake, S., y Meedeniya, D.: 2023b, in *Proceedings of the IEEE International Joint Conference on Biometrics (IJCB)*

Stragapede, G., Vera-Rodriguez, R., Tolosana, R., Morales, A., Acien, A., y Le Lan, G.: 2022a, *Pattern Recognition Letters* **157**, 35

Stragapede, G., Vera-Rodriguez, R., Tolosana, R., Morales, A., Fierrez, J., Ortega-Garcia, J., Rasnayaka, S., Seneviratne, S., Dissanayake, V., Liebers, J., Islam, A., Belhaouari, S. B., Ahmad, S., y Jabin, S.: 2022b, *IJCB 2022 Mobile Behavioral Biometrics Competition (MobileB2C)*

Stragapede, G., Vera-Rodriguez, R., Tolosana, R., Morales, A., Fierrez, J., Ortega-Garcia, J., Rasnayaka, S., Seneviratne, S., Dissanayake, V., Liebers, J., Islam, A., Belhaouari, S. B., Ahmad, S., y Jabin, S.: 2022c, in *Proceedings of the IEEE International Joint Conference on Biometrics (IJCB)*

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., y Polosukhin, I.: 2017, in *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 30